

Université Sorbonne Paris Nord – Institut Galilée

LAGA – UMR CNRS 7539, équipe Probabilités et Statistique

Rapport de stage

Confidentialité différentielle

Mécanismes de bruit et compromis confidentialité–utilité

Ndeye Amy DIOP

Encadrement : Clément Foucart

Période : du 15 juin au 15 août 2026

Année universitaire 2025–2026

Résumé

Ce rapport présente le travail réalisé pendant mon stage au LAGA autour de la confidentialité différentielle. La question étudiée est la suivante : comment publier des informations statistiques utiles sans révéler excessivement la contribution d'une personne ? Pour comprendre l'origine de ce problème, je m'appuie d'abord sur plusieurs cas documentés de ré-identification. Ils montrent que la suppression des identifiants directs ne suffit pas toujours, notamment lorsque les données publiées peuvent être croisées avec des sources extérieures. Le rôle du chiffrement est également précisé : il protège l'accès aux données, mais ne contrôle pas les informations qui peuvent être déduites d'un résultat statistique rendu public.

Le rapport présente ensuite les principales notions mathématiques de la confidentialité différentielle : l'adjacence entre deux bases, la sensibilité d'une requête, les paramètres de confidentialité et les mécanismes de Laplace et de Gauss. Une attention particulière est portée au compromis entre confidentialité et utilité, ainsi qu'aux effets de la répétition des requêtes sur le budget de confidentialité. Enfin, les limites pratiques de la méthode sont discutées, notamment le choix des paramètres, le contrôle des contributions individuelles et l'articulation avec les autres mesures de protection des données.

Mots-clés : confidentialité différentielle, ré-identification, bases adjacentes, sensibilité, mécanismes aléatoires, protection des données.

Table des matières

1	Introduction	4
2	Présentation du laboratoire et cadre du stage	4
2.1	Le LAGA	4
2.2	L'équipe Probabilités et Statistique	4
2.3	Organisation du travail et missions	5
3	Pourquoi la confidentialité différentielle ?	5
3.1	La ré-identification malgré la suppression des identifiants : l'affaire William Weld	6
3.2	D'autres exemples de ré-identification	7
3.3	Les limites du chiffrement pour la publication statistique	8
3.4	Limiter le risque supplémentaire lié à la participation	8
4	Fondements mathématiques	9
4.1	Notations et définitions préliminaires	9
4.2	La notion d'adjacence	10
4.3	Définition de la confidentialité différentielle	10
4.4	Interprétation de la garantie et rôle de ε	11
4.5	La sensibilité d'une fonction	12
4.6	Le mécanisme de Laplace	12
4.7	Mécanisme gaussien	13
5	Interprétation comme test statistique	17
5.1	Le point de vue de l'attaquant	17
5.2	Perte de confidentialité	18
5.3	Erreurs du test	19
6	Développement du logiciel	20
6.1	Organisation du programme	20
6.2	Choix des données et préparation	20
6.3	Application des mécanismes	21

6.4	Résultats et visualisations	21
6.5	Diagnostic numérique de la garantie	22
6.6	Simulation du point de vue de l'attaquant	22
6.7	Difficultés rencontrées	23
7	Limites pratiques de la confidentialité différentielle	23
7.1	Le choix des bornes et des contributions	23
7.2	Le choix de ε	24
7.3	Ce que la garantie ne couvre pas	24
8	Conclusion	24
	Références	26

1 Introduction

La publication de statistiques pose une difficulté simple à formuler : comment apprendre quelque chose sur une population sans révéler d'information sur une personne en particulier ? Supprimer les noms ne suffit pas toujours. Des variables apparemment ordinaires, comme l'âge, le sexe ou le code postal, peuvent permettre une ré-identification lorsqu'elles sont croisées avec une autre source.

Pendant mon stage au sein de LAGA – UMR CNRS 7539, équipe Probabilités et Statistique, je me suis intéressée à la confidentialité différentielle, introduite par Dwork et ses coauteurs [2]. Cette notion ne cherche pas à empêcher toute déduction à partir d'une base de données. Elle cherche plutôt à rendre difficile la détection de la présence d'un individu dans cette base.

Mon travail a d'abord consisté à comprendre les principaux résultats théoriques, avant de les mobiliser dans le développement d'un logiciel. La question qui a guidé l'étude est la suivante :

Comment choisir et calibrer un mécanisme aléatoire afin de limiter la divulgation d'informations individuelles tout en conservant des résultats statistiques exploitables ?

Après la présentation du laboratoire et du cadre du stage, le rapport expose les motivations de la confidentialité différentielle, puis ses fondements mathématiques et son interprétation comme test statistique. Il présente ensuite le logiciel développé pour mettre ces notions en pratique, avant de discuter les limites pratiques de la méthode.

2 Présentation du laboratoire et cadre du stage

2.1 Le LAGA

Mon stage s'est déroulé au Laboratoire Analyse, Géométrie et Applications (LAGA), unité mixte de recherche UMR 7539 associée au CNRS. Le laboratoire est rattaché à l'Institut Galilée de l'Université Sorbonne Paris Nord ainsi qu'à l'Université Paris 8. Ses activités couvrent plusieurs domaines des mathématiques fondamentales et appliquées : géométrie, équations aux dérivées partielles, analyse numérique, probabilités, statistique, cryptographie ou encore traitement de l'image [15].

Le LAGA rassemble des chercheurs et enseignants-chercheurs, des personnels d'appui à la recherche, des doctorants et des chercheurs invités. Son activité scientifique s'organise notamment autour de séminaires, de groupes de travail, de collaborations et de l'encadrement de doctorants.

2.2 L'équipe Probabilités et Statistique

J'ai été accueillie dans l'équipe Probabilités et Statistique. Ses thématiques comprennent notamment les arbres et graphes aléatoires, les équations différentielles stochastiques, les

modèles combinatoires, les milieux aléatoires, les probabilités numériques, les mathématiques financières, les processus gaussiens et la statistique [16].

Mon sujet, intitulé *Confidentialité différentielle*, s'inscrit dans cette équipe par l'utilisation de mécanismes aléatoires pour limiter les informations révélées lors de la publication de statistiques. Le stage s'est déroulé du 15 juin au 15 août 2026 sous l'encadrement de Clément Foucart. Nicolas Vauchelet était l'enseignant référent pour la formation MACS.

2.3 Organisation du travail et missions

Le stage se déroulait principalement à distance. Une réunion de suivi avait lieu chaque semaine avec mon tuteur, en présentiel ou en visioconférence selon les disponibilités. Au début de chaque séance, je présentais brièvement mes recherches et les avancées réalisées depuis notre dernier échange. Nous examinions ensuite les résultats obtenus, les difficultés rencontrées et les éventuelles réorientations à apporter. La réunion se terminait par la définition des objectifs à atteindre avant la séance suivante. Entre ces rendez-vous, j'avais de manière autonome et pouvais solliciter mon tuteur par courrier électronique en cas de besoin.

Le travail s'est organisé en trois étapes. La première semaine a été consacrée au contexte historique de la confidentialité différentielle. J'ai étudié les limites rencontrées par les méthodes antérieures ainsi que les problèmes ayant progressivement conduit à l'introduction de cette nouvelle garantie.

À partir de la deuxième semaine et jusqu'à la première semaine du second mois, je me suis concentrée sur l'étude théorique de la confidentialité différentielle. Cette phase portait notamment sur les bases adjacentes, la sensibilité des requêtes, la définition mathématique de la confidentialité différentielle et les principaux mécanismes permettant de la garantir.

La dernière partie du stage a été consacrée à la mise en pratique des notions étudiées à travers le développement du logiciel. Cette organisation m'a permis de partir du contexte et des motivations de la méthode, d'en étudier ensuite les fondements mathématiques, puis de les mobiliser dans un travail d'implémentation.

3 Pourquoi la confidentialité différentielle ?

La diffusion de données ou de résultats statistiques soulève une question : comment fournir des informations utiles sur une population tout en protégeant les personnes concernées ? Les informations communiquées peuvent prendre la forme d'un fichier dont les identifiants directs ont été retirés, mais aussi de résultats agrégés, comme une moyenne ou un comptage.

Les exemples suivants montrent d'abord que la suppression des identifiants directs ne suffit pas à empêcher une ré-identification. Des données médicales, des historiques de recherche ou des notes de films peuvent notamment être rapprochés d'autres sources pour retrouver l'identité d'une personne. Nous examinerons ensuite pourquoi le chiffrement ne résout pas à lui seul le problème : le destinataire autorisé à lire les résultats peut également chercher à en déduire des informations privées.

Ces constats conduisent à préciser la protection que l'on souhaite apporter aux individus. Une personne peut faire l'objet de déductions sans même avoir participé à une étude. La question est alors de savoir comment limiter le risque supplémentaire auquel sa participation l'expose. Cette réflexion permet d'introduire l'objectif de la confidentialité différentielle avant d'en présenter la définition mathématique.

3.1 La ré-identification malgré la suppression des identifiants : l'affaire William Weld

L'un des exemples les plus connus de ré-identification concerne William Weld, qui était alors gouverneur du Massachusetts. Le 18 mai 1996, il s'effondre au cours d'une cérémonie de remise de diplômes au Bentley College et doit être hospitalisé. L'événement est public et son hospitalisation est rapportée dans la presse [7].

À cette période, la Massachusetts Group Insurance Commission (GIC), chargée de l'achat de l'assurance maladie des employés de l'État, recueille des données sur les soins concernant environ 135 000 employés et membres de leur famille. Le fichier comporte près de cent attributs par passage médical et est transmis à des chercheurs et à des acteurs de l'industrie. Avant cette diffusion, les noms, les adresses et les numéros de sécurité sociale sont supprimés. En revanche, le code postal, la date de naissance et le sexe restent présents [6].

Latanya Sweeney, alors doctorante au MIT, étudie le risque de ré-identification [7]. Elle achète pour vingt dollars la liste électorale de la ville de Cambridge, où réside William Weld, et la reçoit sur deux disquettes. Ce fichier contient le nom et l'adresse des électeurs, mais aussi leur code postal, leur date de naissance et leur sexe [6].

Les deux fichiers ont donc trois variables en commun : le code postal, la date de naissance et le sexe. Dans la liste électorale, ces variables sont associées au nom. Dans les données de la GIC, elles sont associées aux diagnostics, aux actes médicaux et aux médicaments. Elles permettent ainsi de relier les deux fichiers [6].

Elle procède par filtres successifs. Le résultat se resserre de la manière suivante :

- six personnes de la liste électorale de Cambridge partagent la date de naissance de William Weld ;
- parmi ces six personnes, trois sont des hommes ;
- parmi ces trois hommes, un seul habite dans le même code postal que le gouverneur.

Après le croisement des trois critères, William Weld correspond à une seule personne dans la liste électorale de Cambridge. Sweeney retrouve ainsi son dossier dans les données de la GIC, puis en envoie une copie au bureau du gouverneur [8].

Cette ré-identification ne repose pas sur une intrusion dans le système de la GIC. Elle repose sur le rapprochement de deux fichiers à partir de variables communes. La suppression du nom empêchait une identification directe, mais pas une identification par recoupement.

Le code postal, la date de naissance et le sexe jouent ici le rôle de *quasi-identifiants*. Pris séparément, ils ne donnent pas directement le nom de la personne ; leur combinaison peut

toutefois être rare dans une population donnée. À partir des données du recensement de 1990, Sweeney a estimé que 216 millions de personnes sur 248 millions aux États-Unis, soit environ 87 %, étaient probablement uniques selon le triplet formé par le code postal à cinq chiffres, la date de naissance et le sexe [5, 6]. Cette estimation concerne cette population et ces variables précises ; elle ne constitue pas un taux universel de ré-identification.

3.2 D'autres exemples de ré-identification

L'affaire Weld n'est pas un cas isolé. J'ai retenu trois autres exemples qui montrent que le problème apparaît avec des données très différentes.

Table 1: Exemples de ré-identification après publication de données

Cas	Données publiées	Principe du recoupement
AOL (2006)	Requêtes de recherche associées à des identifiants numériques	Certaines recherches contenaient des lieux, des noms et des préoccupations personnelles. Des journalistes ont pu retrouver l'identité d'une utilisatrice à partir de cet ensemble d'indices [11].
Netflix (2006–2008)	Notes attribuées à des films par des utilisateurs pseudonymisés	Les dates et les notes ont été rapprochées de critiques publiques sur IMDb. La rareté de certains profils de notation a permis de ré-identifier des utilisateurs [12].
Données génomiques (2013)	Profils génétiques accessibles pour la recherche	Des chercheurs ont relié des marqueurs du chromosome Y à des bases généalogiques publiques afin d'inférer des noms de famille [13].

Ces attaques n'utilisent pas toutes la même technique, mais leur logique est proche. Une publication est comparée à une information disponible ailleurs. La quantité de données publiques augmente avec les réseaux sociaux, les annuaires et les bases ouvertes ; il devient donc difficile de connaître à l'avance toutes les connaissances d'un futur attaquant.

Ces exemples présentent un autre point commun : la ré-identification ne résulte pas d'une intrusion dans le système qui contenait la base originale. Les données avaient été communiquées ou rendues accessibles après le retrait de certains identifiants. Le risque apparaît ensuite lorsqu'elles sont rapprochées d'informations provenant d'une autre source.

La question du chiffrement est donc différente. Elle concerne principalement la protection des données contre un accès non autorisé pendant leur stockage ou leur transmission.

3.3 Les limites du chiffrement pour la publication statistique

Les exemples précédents montrent que la suppression des identifiants directs ne suffit pas à empêcher une ré-identification. Le chiffrement constitue une autre protection possible : il rend les données illisibles pour une personne qui ne possède pas la clé nécessaire à leur déchiffrement.

Dans une communication chiffrée, cette clé permet de distinguer le destinataire du message d'un adversaire qui chercherait à l'intercepter. Cependant, dans le contexte de la publication statistique, le destinataire peut lui-même être l'adversaire. Une personne autorisée à consulter les résultats peut chercher à les exploiter pour obtenir des informations privées sur les individus [2].

Le problème subsiste donc même lorsque le chiffrement fonctionne correctement. Une fois les résultats accessibles à leur destinataire, il ne contrôle pas les déductions que celui-ci peut effectuer. La protection recherchée doit ainsi porter sur les informations communiquées elles-mêmes, sans supposer que la personne qui les reçoit soit bien intentionnée. La question devient alors celle de la garantie que l'on peut apporter aux individus tout en conservant des résultats statistiques utiles.

3.4 Limiter le risque supplémentaire lié à la participation

Ces risques peuvent susciter des réticences à communiquer ses données personnelles. Une personne sollicitée pour une étude peut légitimement se demander si sa participation permettra d'apprendre davantage d'informations sur elle.

Une première exigence pourrait consister à empêcher toute déduction nouvelle sur un individu. Dalenius exprime cet objectif en proposant que l'accès à une base statistique ne permette rien d'apprendre sur une personne qui ne puisse être appris sans cet accès [1]. L'exemple de Terry Gross illustre cependant la difficulté d'une telle exigence [3].

Supposons qu'un adversaire sache que Terry Gross mesure deux pouces de moins que la taille moyenne des femmes lituaniennes, sans connaître cette moyenne. Si une étude publie sa valeur exacte, il peut immédiatement en déduire la taille de Terry Gross. Cette déduction est possible même si elle ne figure pas dans la base utilisée pour le calcul.

Cet exemple montre qu'une personne peut faire l'objet de déductions sans avoir participé à une étude. Il faut donc distinguer les informations apprises grâce aux connaissances générales sur une population du risque supplémentaire créé par la contribution individuelle.

La confidentialité différentielle vise à contrôler ce risque supplémentaire. Elle considère une même personne dans deux situations : l'une où ses données sont incluses dans la base, l'autre où elles en sont absentes, les autres enregistrements restant inchangés. Elle impose que les distributions des résultats produits dans ces deux situations restent proches, selon une borne déterminée par les paramètres de confidentialité [4].

L'objectif est ainsi de limiter ce que la décision de participer change pour l'individu. La garantie ne promet pas qu'aucune information ne pourra être apprise sur lui : elle encadre l'effet supplémentaire de sa contribution sur les résultats publiés et sur les déductions qui en découlent.

Cette approche permet de rechercher des informations utiles sur la population tout en protégeant les contributions individuelles, y compris lorsque le destinataire cherche à les exploiter. Sa formalisation nécessite d'abord de définir deux bases qui diffèrent par au plus une contribution : c'est la notion de bases adjacentes, présentée dans la section suivante.

4 Fondements mathématiques

La confidentialité différentielle compare les résultats d'un même mécanisme sur deux bases qui diffèrent par la contribution d'un individu. Cette partie précise les notations et les définitions nécessaires, puis présente les mécanismes de Laplace et de Gauss avec leurs démonstrations. Elle explique ensuite comment les garanties évoluent lorsque plusieurs résultats sont publiés.

4.1 Notations et définitions préliminaires

Bases de données et requêtes. L'ensemble des bases possibles est noté $\mathcal{D}$. Une base est notée x ou y ; chaque enregistrement représente ici la contribution d'un individu. Une requête numérique est une fonction $f : \mathcal{D} \rightarrow \mathbb{R}^d$. Le résultat exact $f(x)$ est un nombre si $d = 1$, ou un vecteur de d résultats si $d > 1$.

Mécanismes aléatoires. Un mécanisme M produit le résultat destiné à être communiqué. Sa sortie $M(x)$ est une variable aléatoire, car le calcul peut faire intervenir des tirages au hasard. Il faut distinguer $f(x)$, qui est le résultat exact, de $M(x)$, qui est le résultat publié. Pour une même base, deux exécutions du mécanisme peuvent donner des sorties différentes.

Probabilités et densités. L'espace des sorties est noté $\mathcal{R}$. Pour un ensemble mesurable $S \subseteq \mathcal{R}$, la notation $\Pr[M(x) \in S]$ désigne la probabilité que le résultat publié appartienne à S . La base x est fixée : la probabilité porte sur l'aléa du mécanisme. Par exemple, pour une sortie réelle, S peut être un intervalle.

Lorsque $M(x)$ possède une densité sur $\mathbb{R}^d$, celle-ci est notée $Q(z \mid x)$ et

$$\Pr[M(x) \in S] = \int_S Q(z \mid x) \, dz.$$

Une densité au point z n'est pas la probabilité d'obtenir exactement z : pour une loi à densité, cette dernière probabilité est nulle.

Normes et produit scalaire. Pour $u = (u_1, \dots, u_d) \in \mathbb{R}^d$, on utilise

$$\|u\|_1 = \sum_{i=1}^d |u_i|, \quad \|u\|_2 = \left(\sum_{i=1}^d u_i^2 \right)^{1/2}.$$

Le produit scalaire de u et v est $\langle u, v \rangle = \sum_{i=1}^d u_i v_i$. La matrice identité de taille d est notée I_d . Enfin, $\ln$ désigne le logarithme naturel et $\exp(t) = e^t$ la fonction exponentielle.

Paramètres de confidentialité. Les paramètres $\varepsilon \geq 0$ et $0 \leq \delta < 1$ servent à comparer les probabilités des sorties sur deux bases adjacentes. La notation $x \sim y$ désigne cette relation d’adjacence, définie ci-dessous.

4.2 La notion d’adjacence

Dans ce rapport, deux bases sont dites adjacentes si l’une peut être obtenue à partir de l’autre par l’ajout ou la suppression d’au plus un enregistrement. Cette convention permet de comparer la présence et l’absence d’une même contribution, les autres enregistrements restant inchangés.

Pour formaliser cette idée, considérons un ensemble fini de m types d’enregistrements. Une base peut être représentée par un histogramme

$$x = (x_1, \dots, x_m) \in \mathbb{N}^m,$$

où $\mathbb{N} = \{0, 1, 2, \dots\}$ et où x_i compte les enregistrements du type i . Le nombre m de types possibles est distinct du nombre d de coordonnées du résultat d’une requête.

La distance entre deux bases est alors

$$\|x - y\|_1 = \sum_{i=1}^m |x_i - y_i|.$$

Dans la convention par ajout ou suppression, l’adjacence est définie par

$$x \sim y \iff \|x - y\|_1 \leq 1. \quad (1)$$

Les coordonnées étant entières, cette distance vaut soit 0, soit 1. Les bases sont donc identiques, ou diffèrent par l’ajout ou la suppression d’un seul enregistrement. Inclure les bases identiques ne pose pas de difficulté : l’inégalité de confidentialité sera automatiquement vérifiée dans ce cas.

Par exemple, retirer un enregistrement de la première catégorie de $x = (5, 3, 0)$ donne $y = (4, 3, 0)$. On a bien

$$\|x - y\|_1 = |5 - 4| + |3 - 3| + |0 - 0| = 1.$$

Cette convention est aussi appelée modèle *non borné* [4, 9].

4.3 Définition de la confidentialité différentielle

4.3.1 Énoncé général

Un mécanisme aléatoire M est (ε, δ) -différentiellement privé si, pour toutes bases adjacentes x, y et tout ensemble mesurable de sorties $S \subseteq \mathcal{R}$,

$$\Pr[M(x) \in S] \leq e^\varepsilon \Pr[M(y) \in S] + \delta. \quad (2)$$

L'adjacence étant symétrique, cette condition doit aussi être satisfaite en échangeant x et y :

$$\Pr[M(y) \in S] \leq e^\varepsilon \Pr[M(x) \in S] + \delta.$$

La définition porte donc sur toutes les bases adjacentes et sur tous les événements de sortie, pas uniquement sur un résultat moyen ou sur les bases observées pendant une expérience [4].

4.3.2 Rôle du paramètre delta

Le paramètre δ autorise un relâchement additif de la comparaison des probabilités. À ε fixé, une valeur plus petite impose une garantie plus contraignante. Il ne faut pas interpréter la définition générale comme l'affirmation qu'une proportion δ des personnes ou des sorties n'est pas protégée. Certaines preuves utilisent un événement exceptionnel de probabilité au plus δ , mais cette construction constitue une condition suffisante particulière.

4.3.3 Cas particulier : confidentialité pure

Lorsque $\delta = 0$, on parle de confidentialité différentielle pure, ou de garantie ε -DP. La définition devient

$$\Pr[M(x) \in S] \leq e^\varepsilon \Pr[M(y) \in S].$$

Lorsque $\delta > 0$, on parle de confidentialité différentielle approchée.

4.4 Interprétation de la garantie et rôle de ε

Dans cette sous-partie, on considère la confidentialité pure, donc $\delta = 0$. Les deux sens de l'inégalité donnent, pour tout événement S de probabilité non nulle,

$$e^{-\varepsilon} \leq \frac{\Pr[M(x) \in S]}{\Pr[M(y) \in S]} \leq e^\varepsilon.$$

Un événement impossible sous une base adjacente est également impossible sous l'autre. Plus ε est petit, plus cet encadrement rapproche les probabilités de sortie.

Pour des sorties discrètes, on peut prendre $S = \{z\}$ et comparer les probabilités de chaque valeur. Pour des sorties à densité, on obtient, presque partout sur le support commun,

$$e^{-\varepsilon} \leq \frac{Q(z | x)}{Q(z | y)} \leq e^\varepsilon.$$

Cette expression concerne les densités et non les probabilités de valeurs isolées. Réciproquement, intégrer cet encadrement des densités redonne la garantie pour tout ensemble mesurable S .

Cet encadrement permet de préciser le rôle du paramètre ε :

- Si $\varepsilon = 0$, les distributions sont identiques sur les bases adjacentes. Sur l'ensemble des bases finies du modèle par ajout/suppression, toute base peut être reliée à toute autre par une suite de modifications élémentaires : la loi de sortie est alors la même pour toutes les bases.

- Si ε est petit, le rapport des probabilités est contraint à rester proche de 1.
- Lorsque ε augmente, la garantie autorise des écarts plus importants. Cela ne prouve pas qu’une attaque réussira : la contrainte imposée au mécanisme devient moins forte.

4.5 La sensibilité d’une fonction

La sensibilité mesure la variation maximale d’une requête lorsque la base subit une modification autorisée par l’adjacence.

Pour $p \in \{1, 2\}$, la sensibilité globale de $f : \mathcal{D} \rightarrow \mathbb{R}^d$ en norme ℓ_p est

$$\Delta_p f = \sup_{x \sim y} \|f(x) - f(y)\|_p.$$

On utilise $\Delta_1 f$ pour le mécanisme de Laplace et $\Delta_2 f$ pour le mécanisme gaussien. Si la borne est atteinte, le supremum peut être écrit comme un maximum. Pour une sortie réelle, les deux normes coïncident et $\Delta_1 f = \Delta_2 f$.

La sensibilité est calculée sur toutes les bases autorisées par le modèle. Elle ne se déduit pas seulement de la variation constatée sur un jeu de données particulier.

4.6 Le mécanisme de Laplace

4.6.1 Définition de la loi de Laplace

Une variable Y suit une loi de Laplace centrée de paramètre $b > 0$, notée $\text{Laplace}(0, b)$, si sa densité est

$$g(t) = \frac{1}{2b} \exp\left(-\frac{|t|}{b}\right), \quad t \in \mathbb{R}.$$

Elle a une espérance nulle et une variance $2b^2$.

4.6.2 Définition du mécanisme et garantie

Soit $f : \mathcal{D} \rightarrow \mathbb{R}^d$ telle que $0 < \Delta_1 f < \infty$, et soit $\varepsilon > 0$. On pose

$$M(x) = f(x) + (Y_1, \dots, Y_d), \quad Y_i \stackrel{\text{i.i.d.}}{\sim} \text{Laplace}\left(0, \frac{\Delta_1 f}{\varepsilon}\right).$$

La notation i.i.d. signifie que les bruits sont indépendants et suivent la même loi. Ce mécanisme est ε -différentiellement privé [4]. Si $\Delta_1 f = 0$, le résultat exact est identique sur les bases adjacentes et aucun bruit n’est nécessaire.

4.6.3 Preuve

Dans cette preuve, on note $\Delta f = \Delta_1 f$. Soient x et y deux bases adjacentes. On a $\|f(x) - f(y)\|_1 \leq \Delta f$. Pour une sortie $z \in \mathbb{R}^d$, l’indépendance des bruits donne le rapport

des densités suivant :

$$\frac{Q(z \mid x)}{Q(z \mid y)} = \frac{\prod_{i=1}^d \frac{\varepsilon}{2\Delta f} \exp\left(-\frac{\varepsilon|z_i - f(x)_i|}{\Delta f}\right)}{\prod_{i=1}^d \frac{\varepsilon}{2\Delta f} \exp\left(-\frac{\varepsilon|z_i - f(y)_i|}{\Delta f}\right)}.$$

En simplifiant les facteurs communs et en regroupant les exponentielles,

$$\frac{Q(z \mid x)}{Q(z \mid y)} = \exp\left(\frac{\varepsilon}{\Delta f} \sum_{i=1}^d (|z_i - f(y)_i| - |z_i - f(x)_i|)\right).$$

Par l'inégalité triangulaire, pour chaque coordonnée i ,

$$|z_i - f(y)_i| \leq |z_i - f(x)_i| + |f(x)_i - f(y)_i|,$$

d'où

$$|z_i - f(y)_i| - |z_i - f(x)_i| \leq |f(x)_i - f(y)_i|.$$

Ainsi,

$$\begin{aligned} \frac{Q(z \mid x)}{Q(z \mid y)} &\leq \exp\left(\frac{\varepsilon}{\Delta f} \sum_{i=1}^d |f(x)_i - f(y)_i|\right) \\ &= \exp\left(\frac{\varepsilon}{\Delta f} \|f(x) - f(y)\|_1\right) \\ &\leq \exp\left(\frac{\varepsilon}{\Delta f} \Delta f\right) = e^\varepsilon. \end{aligned}$$

On obtient donc, pour tout z ,

$$Q(z \mid x) \leq e^\varepsilon Q(z \mid y).$$

En intégrant sur un ensemble mesurable quelconque S ,

$$\begin{aligned} \Pr[M(x) \in S] &= \int_S Q(z \mid x) \, dz \\ &\leq e^\varepsilon \int_S Q(z \mid y) \, dz \\ &= e^\varepsilon \Pr[M(y) \in S]. \end{aligned}$$

Les bases x et y étant arbitraires, le mécanisme de Laplace satisfait bien la définition de la confidentialité différentielle pure.

4.7 Mécanisme gaussien

Énoncé. Soit $f : \mathcal{D} \rightarrow \mathbb{R}^d$ une fonction de sensibilité Δf en norme ℓ_2 , c'est-à-dire que pour toutes bases adjacentes x, y :

$$\|f(x) - f(y)\|_2 \leq \Delta f$$

Le mécanisme gaussien est défini par :

$$M(x) = f(x) + \mathcal{N}(0, \sigma^2 I_d)$$

où $\mathcal{N}(0, \sigma^2 I_d)$ est un bruit gaussien multivarié centré de covariance $\sigma^2 I_d$. Chaque coordonnée reçoit donc un bruit gaussien indépendant de variance σ^2 .

Si l'on choisit :

$$\sigma \geq \frac{\Delta f}{\varepsilon} \sqrt{2 \ln \left(\frac{2}{\delta} \right)}$$

alors M est (ε, δ) -différentiellement privé.

Preuve. La densité de la sortie $z \in \mathbb{R}^d$ sachant que la base est x est donnée par la formule classique de la loi normale multivariée :

$$Q(z|x) = \frac{1}{(2\pi\sigma^2)^{d/2}} \exp \left(-\frac{\|z - f(x)\|_2^2}{2\sigma^2} \right)$$

Cette formule exprime que z a plus de chances d'être proche de $f(x)$ que d'en être loin, avec une décroissance exponentielle de la probabilité en fonction de la distance euclidienne. De la même manière, la densité de la sortie z sachant que la base est y est :

$$Q(z|y) = \frac{1}{(2\pi\sigma^2)^{d/2}} \exp \left(-\frac{\|z - f(y)\|_2^2}{2\sigma^2} \right)$$

On souhaite montrer que le mécanisme est (ε, δ) -différentiellement privé. Pour cela, on va montrer que la probabilité que le rapport $Q(z|x)/Q(z|y)$ dépasse e^ε est inférieure à δ .

On commence par calculer ce rapport. En divisant $Q(z|x)$ par $Q(z|y)$, les facteurs $(2\pi\sigma^2)^{-d/2}$ se simplifient :

$$\frac{Q(z|x)}{Q(z|y)} = \frac{\exp \left(-\frac{\|z - f(x)\|_2^2}{2\sigma^2} \right)}{\exp \left(-\frac{\|z - f(y)\|_2^2}{2\sigma^2} \right)}$$

En utilisant la propriété $\frac{e^A}{e^B} = e^{A-B}$, on obtient :

$$\frac{Q(z|x)}{Q(z|y)} = \exp \left(-\frac{\|z - f(x)\|_2^2}{2\sigma^2} + \frac{\|z - f(y)\|_2^2}{2\sigma^2} \right)$$

On factorise le terme $\frac{1}{2\sigma^2}$:

$$\frac{Q(z|x)}{Q(z|y)} = \exp \left(\frac{\|z - f(y)\|_2^2 - \|z - f(x)\|_2^2}{2\sigma^2} \right)$$

Cette expression montre que le rapport est grand quand z est plus proche de $f(x)$ que de $f(y)$, et petit dans le cas contraire. On veut que ce rapport ne dépasse pas e^ε . Cela équivaut à :

$$\frac{\|z - f(y)\|_2^2 - \|z - f(x)\|_2^2}{2\sigma^2} \leq \varepsilon$$

En multipliant les deux côtés par $2\sigma^2$:

$$\|z - f(y)\|_2^2 - \|z - f(x)\|_2^2 \leq 2\sigma^2\varepsilon$$

C'est la condition que doit vérifier z pour que le mécanisme soit ε -DP. Mais cette condition n'est pas toujours vraie. On va donc évaluer la probabilité qu'elle soit violée.

Pour simplifier cette condition, on utilise une identité algébrique. Pour tous vecteurs $a, b, z \in \mathbb{R}^d$, on a :

$$\|z - b\|_2^2 - \|z - a\|_2^2 = \langle a - b, 2z - a - b \rangle$$

En effet, en développant les carrés des normes, on obtient d'un côté $2\langle z, a - b \rangle + \|b\|^2 - \|a\|^2$, et de l'autre $\langle a - b, 2z - a - b \rangle$, qui est égal à $2\langle z, a - b \rangle - \|a - b\|^2 + \|b\|^2 - \|a\|^2$, c'est-à-dire exactement la même expression. Cette identité est donc vraie.

En prenant $a = f(x)$ et $b = f(y)$, on obtient :

$$\|z - f(y)\|_2^2 - \|z - f(x)\|_2^2 = \langle f(x) - f(y), 2z - f(x) - f(y) \rangle$$

L'inégalité de Cauchy-Schwarz donne alors :

$$\|z - f(y)\|_2^2 - \|z - f(x)\|_2^2 \leq \|f(x) - f(y)\|_2 \cdot \|2z - f(x) - f(y)\|_2$$

Cette majoration est utile car elle fait apparaître la sensibilité Δf . En effet, comme x et y sont adjacentes, on sait que $\|f(x) - f(y)\|_2 \leq \Delta f$. Par conséquent, si la condition suivante est vérifiée :

$$\Delta f \cdot \|2z - f(x) - f(y)\|_2 \leq 2\sigma^2\varepsilon$$

alors la condition précédente, $\|z - f(y)\|_2^2 - \|z - f(x)\|_2^2 \leq 2\sigma^2\varepsilon$, l'est aussi. En divisant par Δf , on obtient la condition suffisante :

$$\|2z - f(x) - f(y)\|_2 \leq \frac{2\sigma^2\varepsilon}{\Delta f}$$

La probabilité que la garantie ε -DP soit violée est donc au plus la probabilité que cette condition soit violée, c'est-à-dire :

$$\Pr \left[\|2z - f(x) - f(y)\|_2 > \frac{2\sigma^2\varepsilon}{\Delta f} \right]$$

Il reste à évaluer cette probabilité. Sous la loi $Q(\cdot|x)$, la sortie z suit une loi normale centrée en $f(x)$ de covariance $\sigma^2 I_d$. La variable $2z - f(x) - f(y)$ suit donc une loi normale centrée en $f(x) - f(y)$, de covariance $4\sigma^2 I_d$. C'est une conséquence directe de la linéarité des lois normales.

Pour borner la queue d'une telle variable, on utilise une inégalité standard de concentration. Pour une gaussienne centrée G de covariance $4\sigma^2 I_d$, la probabilité que sa norme dépasse un seuil t est majorée par :

$$\Pr[\|G\|_2 > t] \leq 2 \exp \left(-\frac{t^2}{8\sigma^2} \right)$$

Cette borne est classique et résulte du fait que la norme au carré d'une gaussienne suit une loi du χ^2 dont on peut majorer les queues. En appliquant cette inégalité avec $t = \frac{2\sigma^2\varepsilon}{\Delta f}$, on obtient :

$$\Pr \left[\|2z - f(x) - f(y)\|_2 > \frac{2\sigma^2\varepsilon}{\Delta f} \right] \leq 2 \exp \left(-\frac{\left(\frac{2\sigma^2\varepsilon}{\Delta f}\right)^2}{8\sigma^2} \right)$$

On simplifie alors le terme dans l'exponentielle. Le carré du numérateur donne $\frac{4\sigma^4\varepsilon^2}{\Delta f^2}$. En divisant par $8\sigma^2$, il reste $\frac{\sigma^2\varepsilon^2}{2\Delta f^2}$. La probabilité d'échec est donc inférieure à :

$$2 \exp \left(-\frac{\sigma^2\varepsilon^2}{2\Delta f^2} \right)$$

On veut que cette probabilité soit au plus δ . On choisit donc σ tel que :

$$2 \exp \left(-\frac{\sigma^2\varepsilon^2}{2\Delta f^2} \right) \leq \delta$$

En résolvant cette inégalité, on obtient successivement :

$$\exp \left(-\frac{\sigma^2\varepsilon^2}{2\Delta f^2} \right) \leq \frac{\delta}{2}$$

$$-\frac{\sigma^2\varepsilon^2}{2\Delta f^2} \leq \ln \left(\frac{\delta}{2} \right)$$

$$\frac{\sigma^2\varepsilon^2}{2\Delta f^2} \geq \ln \left(\frac{2}{\delta} \right)$$

$$\sigma^2 \geq \frac{2\Delta f^2}{\varepsilon^2} \ln\left(\frac{2}{\delta}\right)$$

$$\sigma \geq \frac{\Delta f}{\varepsilon} \sqrt{2 \ln\left(\frac{2}{\delta}\right)}$$

Avec ce choix de σ , la probabilité que le rapport des densités dépasse e^ε est inférieure à δ . Cela signifie qu'il existe un ensemble de sorties de probabilité totale au plus δ pour lesquelles la garantie ε -DP peut être violée. Pour toutes les autres sorties, c'est-à-dire avec probabilité au moins $1 - \delta$, on a bien $Q(z|x) \leq e^\varepsilon Q(z|y)$.

En intégrant cette inégalité sur tout ensemble S de résultats possibles, on obtient la garantie (ε, δ) -DP :

$$\Pr[M(x) \in S] \leq e^\varepsilon \cdot \Pr[M(y) \in S] + \delta$$

Le mécanisme gaussien est donc bien (ε, δ) -différentiellement privé.

5 Interprétation comme test statistique

La confidentialité différentielle peut être interprétée en termes de test d'hypothèse. Un attaquant observe la sortie d'un mécanisme et cherche à déterminer si une personne spécifique est présente dans la base ou non. La définition ε -DP garantit alors que ce test ne peut pas être trop performant : elle borne le rapport des probabilités entre les deux cas. Cette section explicite cette interprétation et introduit les notions de perte de confidentialité, de puissance d'un test et d'erreur de Bayes.

5.1 Le point de vue de l'attaquant

La définition de la confidentialité différentielle peut être lue comme un problème de test. Un attaquant connaît deux bases adjacentes D et D' , mais ignore laquelle a été utilisée. Il observe la sortie Z du mécanisme M et cherche à décider entre deux hypothèses :

- H_0 : la sortie a été produite à partir de D ;
- H_1 : la sortie a été produite à partir de D' .

Dans la convention retenue, D contient la contribution d'une personne ciblée et D' est obtenue en retirant cette contribution. Distinguer les deux bases revient donc à chercher à détecter la participation de cette personne. La performance de l'attaquant s'évalue à partir de ses probabilités de réussite et d'erreur.

Lorsque les lois de sortie admettent des densités, on les note p_D et $p_{D'}$. Pour deux hypothèses simples et un niveau fixé, le lemme de Neyman–Pearson permet de construire un test le plus puissant à partir du rapport de vraisemblance [14] :

$$L(z) = \frac{p_D(z)}{p_{D'}(z)}. \quad (3)$$

Un rapport supérieur à 1 favorise D , tandis qu'un rapport inférieur à 1 favorise D' . Avec l'orientation choisie, le test rejette H_0 lorsque $L(z)$ est inférieur à un seuil. Une décision aléatoire au seuil peut être nécessaire pour atteindre exactement le niveau fixé.

Si $p_{D'}(z) = 0$ et $p_D(z) > 0$, le rapport est interprété comme $+\infty$. Les points de probabilité nulle sous les deux lois n'affectent pas le test. Pour des sorties discrètes, le même raisonnement utilise les probabilités de chaque valeur à la place des densités.

5.2 Perte de confidentialité

Le logarithme du rapport de vraisemblance est appelé perte de confidentialité :

$$\mathcal{L}(z) = \ln L(z) = \ln \left(\frac{p_D(z)}{p_{D'}(z)} \right). \quad (4)$$

Une valeur positive favorise D , une valeur négative favorise D' . Une valeur proche de zéro signifie que les deux vraisemblances sont proches.

Pour un mécanisme ε -différentiellement privé, les deux lois ont les mêmes ensembles de probabilité nulle et

$$e^{-\varepsilon} \leq L(z) \leq e^{\varepsilon}$$

presque sûrement sous chacune d'elles. En prenant le logarithme, on obtient donc $|\mathcal{L}(Z)| \leq \varepsilon$ presque sûrement.

Lorsque ε est faible, le rapport est contraint à rester proche de 1. Lorsque ε augmente, la définition autorise un écart plus important entre les vraisemblances.

Table 2: Effet de ε sur l'encadrement du rapport de vraisemblance

ε	e^{ε} (environ)	Encadrement exact
0,1	1,105	$e^{-0,1} \leq L(z) \leq e^{0,1}$
0,5	1,649	$e^{-0,5} \leq L(z) \leq e^{0,5}$
1	2,718	$e^{-1} \leq L(z) \leq e$
2	7,389	$e^{-2} \leq L(z) \leq e^2$

Ce tableau décrit les écarts autorisés par la garantie, et non ceux qu'un mécanisme atteint nécessairement. Il ne suffit pas à choisir un budget : il faut également considérer le contexte de publication et la composition des mécanismes utilisés.

5.3 Erreurs du test

Un test peut commettre deux types d'erreurs. L'erreur de type I consiste à rejeter H_0 alors que D a été utilisée. On note sa probabilité

$$\alpha = \Pr[\text{rejeter } H_0 \mid H_0].$$

Cette quantité est la taille du test. Un test de niveau fixé doit avoir une taille au plus égale à ce niveau.

L'erreur de type II consiste à ne pas rejeter H_0 alors que la sortie provient de D' . Sa probabilité est notée β . La puissance du test vaut alors

$$\pi = \Pr[\text{rejeter } H_0 \mid H_1] = 1 - \beta.$$

Avec notre convention, elle mesure la probabilité de conclure correctement à l'absence de l'individu lorsque D' a été utilisée.

En appliquant la garantie de confidentialité à l'événement de rejet, dans le sens D' vers D , on obtient $\pi \leq e^\varepsilon \alpha$. Comme la puissance est une probabilité,

$$\pi \leq \min\{1, e^\varepsilon \alpha\}. \quad (5)$$

Pour $\varepsilon = 0$, les deux lois sont identiques et $\pi = \alpha$. Le test ne distingue alors pas mieux les hypothèses qu'une décision indépendante de l'observation, qui rejette H_0 avec probabilité α . Pour un petit ε , la garantie limite l'écart possible entre ces deux probabilités.

Une autre mesure est l'erreur de Bayes, définie comme la plus petite probabilité moyenne d'erreur parmi tous les tests. Lorsque les deux hypothèses sont équiprobables, l'erreur moyenne d'un test vaut $(\alpha + \beta)/2$.

La garantie pure, appliquée à l'événement de rejet puis à son complémentaire dans les deux sens appropriés, donne

$$1 - \beta \leq e^\varepsilon \alpha, \quad 1 - \alpha \leq e^\varepsilon \beta.$$

En additionnant ces inégalités, on obtient $2 \leq (1 + e^\varepsilon)(\alpha + \beta)$. Ainsi,

$$\text{Err}_{\text{Bayes}} \geq \frac{1}{1 + e^\varepsilon}. \quad (6)$$

Pour $\varepsilon = 0$, cette borne vaut $1/2$. Pour $\varepsilon = 1$, elle vaut environ 0,269. Il s'agit d'une borne inférieure sur l'erreur, et non de l'erreur effectivement atteinte par chaque mécanisme. Sa diminution ne prouve donc pas qu'une attaque réussira.

Ces bornes restent valables pour les tests qui utilisent une décision aléatoire.

6 Développement du logiciel

La partie pratique du stage a consisté à développer une interface permettant d'expérimenter les mécanismes de confidentialité différentielle étudiés dans la partie théorique. L'objectif était de rendre visibles les effets du bruit, du choix de ε et de la sensibilité sur un résultat statistique. Le programme a été écrit en Python. L'interface graphique repose sur Tkinter et les graphiques sont produits avec Matplotlib.

6.1 Organisation du programme

Le fichier principal définit la classe `DPApp`, qui organise les éléments de l'interface et les actions déclenchées par l'utilisateur. Les fonctions de l'application sont séparées en plusieurs modules :

- le module `data` fournit les jeux de données disponibles et leurs noms ;
- le module `utils` calcule la statistique demandée et sa sensibilité ;
- le module `mechanisms` contient les fonctions associées aux mécanismes de Laplace et de Gauss ;
- le module `verification` fournit le diagnostic numérique affiché par le bouton de vérification.

Cette organisation sépare l'interface, les calculs statistiques, les mécanismes aléatoires et la vérification. Le fichier principal fourni pour le rapport est syntaxiquement valide ; l'exécution complète dépend toutefois des quatre modules auxiliaires mentionnés ci-dessus.

6.2 Choix des données et préparation

L'utilisateur peut sélectionner un jeu de données proposé par le programme, ou charger un fichier CSV contenant des valeurs numériques. Le code prévoit notamment des jeux de données correspondant aux salaires, aux âges et à des données médicales. Lors du chargement d'un jeu prédéfini, des bornes de clipping sont associées au type de données : $[0, 100]$ pour les âges, $[0, 15]$ pour les données médicales et $[0, 100000]$ pour les salaires.

Avant le calcul, chaque valeur est remplacée par sa projection dans l'intervalle choisi :

$$x \longmapsto \min\left(\max(x, c_{\min}), c_{\max}\right).$$

Cette étape limite l'influence des valeurs extrêmes et permet de calculer une sensibilité à partir de bornes explicites. L'interface propose ensuite trois statistiques : la moyenne, le comptage et la somme. Un seuil numérique est également disponible pour les statistiques qui en ont besoin.

6.3 Application des mécanismes

Après le clipping, le programme calcule la valeur exacte de la statistique et la sensibilité correspondante. L'utilisateur choisit ensuite le mécanisme et le paramètre de confidentialité.

Pour le mécanisme de Laplace, le bruit est calibré à partir de la sensibilité et de ε . Le résultat affiché est donc une valeur numérique perturbée autour de la statistique exacte.

Pour le mécanisme gaussien, deux possibilités sont proposées. Le programme peut calculer automatiquement un écart-type à partir de la sensibilité, de ε et de δ , ou utiliser une valeur de σ saisie manuellement. Le mode manuel sert à explorer l'effet de différents niveaux de bruit ; il ne garantit pas à lui seul que le calibrage choisi respecte une garantie (ε, δ) donnée.

6.4 Résultats et visualisations

Après chaque calcul, l'interface affiche :

- la statistique exacte ;
- le mécanisme utilisé et la valeur de ε ;
- la valeur de σ lorsque le mécanisme gaussien est sélectionné ;
- le résultat bruité ;
- l'écart absolu entre le résultat exact et le résultat publié ;
- la sensibilité utilisée pour le calcul.

Un premier graphique représente l'histogramme des données. Le bouton « Graphiques » lance ensuite une simulation répétée : le code produit mille sorties bruitées afin de visualiser la distribution du résultat pour le mécanisme sélectionné. Cette visualisation permet d'observer la dispersion autour de la valeur exacte et d'interpréter le compromis entre confidentialité et précision lorsque le bruit est recalibré.




Figure 1: Interface du logiciel : comparaison entre la valeur réelle et la valeur bruitée

Cette capture montre la comparaison entre la statistique calculée sans bruit et la valeur obtenue après application du mécanisme de Laplace. La différence entre les deux barres correspond à l'erreur introduite par le bruit. Cet exemple illustre le compromis entre confidentialité et précision : le résultat publié n'est pas exactement égal à la valeur réelle, mais il reste exploitable.

6.5 Diagnostic numérique de la garantie

Le bouton « Diagnostic numérique » calcule e^ε , un rapport estimé et une borne d'erreur de Bayes, puis compare le rapport obtenu à la borne attendue. Ce calcul sert à examiner le comportement observé sur une simulation. Il ne constitue pas une preuve de confidentialité différentielle : une simulation finie ne peut pas vérifier une inégalité mathématique pour tous les ensembles de sorties et toutes les bases adjacentes. La garantie repose sur l'énoncé et la preuve du mécanisme, ainsi que sur le respect des hypothèses de sensibilité et de calibrage.

Le calibrage affiché pour σ dans l'interface doit être identique à celui utilisé à l'intérieur de `gaussian_mechanism_from_eps_delta`. Cette vérification est nécessaire pour que l'interprétation du résultat corresponde au bruit effectivement simulé.

6.6 Simulation du point de vue de l'attaquant

Le bouton « Attaque » reprend la même question que l'interprétation statistique présentée précédemment. À partir de la base chargée, le programme construit une base adjacente en retirant un enregistrement. Il calcule ensuite la statistique sur les deux bases et simule des sorties du mécanisme dans les deux hypothèses. Pour chaque sortie observée, un classifieur compare les deux densités théoriques et choisit l'hypothèse la plus vraisemblable. L'interface affiche alors le taux de décisions correctes et représente les deux distributions de sorties.

Cette expérience permet d'interpréter concrètement la garantie : lorsque les distributions se recouvrent largement, l'attaquant distingue difficilement la présence ou l'absence de l'enregistrement. Lorsque ε augmente, le bruit est généralement plus faible et la distinction peut devenir plus facile. Le taux obtenu dépend toutefois du jeu de données, de la statistique et du nombre de simulations ; il s'agit donc d'une illustration expérimentale et non d'une preuve de confidentialité différentielle.

La figure suivante est une illustration indépendante obtenue sur une base synthétique avec une requête de comptage. Elle sert à rendre visible le recouvrement des sorties ; elle ne représente pas les résultats d'une base personnelle ni une exécution particulière de l'utilisateur.




Figure 2: Illustration synthétique des sorties du mécanisme de Laplace sur deux bases adjacentes pour une requête de comptage. Les deux distributions se recouvrent davantage pour $\varepsilon = 0,2$ que pour $\varepsilon = 1$; la décision de l’attaquant est alors plus difficile dans le premier cas.

6.7 Difficultés rencontrées

La mise en œuvre a nécessité de relier les notions théoriques aux calculs effectués par le programme. Les principales difficultés ont concerné la compréhension de la sensibilité, la distinction entre deux bases adjacentes et la simulation d’une attaque fondée sur les sorties du mécanisme. Ces points sont importants dans l’interface : la sensibilité détermine la quantité de bruit ajoutée, tandis que la comparaison entre une statistique exacte et une statistique bruitée permet d’observer concrètement le compromis entre confidentialité et utilité.

7 Limites pratiques de la confidentialité différentielle

7.1 Le choix des bornes et des contributions

Pour des statistiques comme la moyenne, le modèle par ajout ou suppression demande de borner les valeurs individuelles et de préciser une taille minimale de la base. Une borne trop basse peut écrêter de nombreuses observations et introduire un biais. Une borne trop élevée augmente la quantité de bruit sans nécessairement apporter beaucoup d’information supplémentaire.

Le bornage fait donc partie du modèle statistique. Il devrait être défini à partir d’une connaissance du domaine et, autant que possible, avant d’examiner les données sensibles. Le choisir après avoir observé la valeur maximale peut lui-même divulguer une information.

7.2 Le choix de ε

Un petit ε renforce la garantie mais augmente généralement le bruit. Il n'existe cependant pas de valeur optimale indépendante du contexte. Le choix dépend de la précision minimale utile, de la nature des informations protégées et du nombre de traitements prévus.

Une présentation limitée à « petit ε = bonne protection » serait donc incomplète. Le paramètre doit être accompagné de la définition de l'adjacence, de la valeur de δ lorsqu'elle existe, de la méthode de composition et des règles de limitation des contributions individuelles.

7.3 Ce que la garantie ne couvre pas

La confidentialité différentielle contrôle l'influence d'une ligne sur une sortie. Elle ne corrige pas une mauvaise gestion des accès à la base originale, une erreur d'implémentation ou la publication accidentelle d'un fichier non protégé. Elle ne garantit pas non plus que toutes les conclusions sur une population seront inoffensives. Une statistique exacte ou privée peut révéler une tendance réelle concernant un groupe.

La méthode doit donc être associée à des mesures classiques de sécurité, à une documentation des paramètres et à une analyse du contexte d'utilisation. Sa force est de fournir une garantie mesurable sur un aspect précis du risque, et non de résoudre à elle seule toutes les questions de protection des données.

8 Conclusion

Ce stage m'a permis d'étudier une question centrale de la confidentialité différentielle : comment publier des informations statistiques utiles tout en limitant ce que la contribution d'une personne peut révéler ? Les exemples de ré-identification présentés dans ce rapport montrent que la suppression des identifiants directs ne suffit pas toujours. Le croisement avec des sources extérieures peut permettre de retrouver une personne, tandis que le chiffrement protège principalement l'accès aux données et non les déductions effectuées à partir d'un résultat publié.

L'étude théorique m'a ensuite permis de préciser les notions nécessaires à la formalisation de cette garantie. L'adjacence définit la modification prise en compte, la sensibilité mesure l'influence maximale de cette modification sur une requête, et les paramètres ε et δ contrôlent le niveau de protection recherché. Les mécanismes de Laplace et de Gauss montrent comment un bruit aléatoire peut être calibré à partir de ces quantités. La composition rappelle également que plusieurs publications sur une même base doivent être considérées ensemble.

La partie pratique a prolongé cette étude par le développement d'une interface en Python. Elle permet de charger des données, de choisir une statistique, d'appliquer un clipping, de sélectionner un mécanisme et d'observer la différence entre le résultat exact et le résultat bruité. La simulation du point de vue de l'attaquant permet de comparer les sorties obtenues sur deux bases adjacentes. Lorsque les distributions se recouvrent davantage, la présence ou l'absence d'une contribution est plus difficile à détecter. Cette simulation

reste cependant une illustration expérimentale et ne remplace pas la preuve mathématique de la garantie.

Ce travail m'a également montré que la confidentialité différentielle ne constitue pas une protection générale contre tous les risques. Le choix des bornes, le calcul de la sensibilité, le budget de confidentialité, la composition des requêtes et la qualité de l'implémentation doivent être examinés avec attention. La méthode doit donc être associée à des mesures classiques de sécurité et à une analyse du contexte d'utilisation. Une prolongation naturelle consisterait à améliorer le suivi du budget lors de publications multiples et à étudier des méthodes de composition plus fines.

Références

- [1] T. Dalenius, *Towards a Methodology for Statistical Disclosure Control*, Statistik Tidskrift, vol. 15, p. 429–444, 1977.
- [2] C. Dwork, *Differential Privacy*, ICALP, p. 1–12, 2006.
- [3] C. Dwork et M. Naor, *On the Difficulties of Disclosure Prevention in Statistical Databases*, Journal of Privacy and Confidentiality, vol. 2, no 1, p. 93–107, 2010.
- [4] C. Dwork et A. Roth, *The Algorithmic Foundations of Differential Privacy*, Foundations and Trends in Theoretical Computer Science, vol. 9, 2014.
- [5] L. Sweeney, *Simple Demographics Often Identify People Uniquely*, Carnegie Mellon University, Data Privacy Working Paper 3, 2000.
- [6] L. Sweeney, *Recommendations to Identify and Combat Privacy Problems in the Commonwealth*, témoignage devant la Pennsylvania House Select Committee on Information Security, 5 octobre 2005.
[Texte publié par le Data Privacy Lab.](#)
- [7] S. L. Garfinkel et M. Theofanos, *Non-Breach Privacy Events*, Technology Science, article 2018100903, 8 octobre 2018.
[Article en ligne.](#)
- [8] V. Janmey et P. L. Elkin, *Re-Identification Risk in HIPAA De-Identified Datasets: The MVA Attack*, AMIA Annual Symposium Proceedings, p. 1329–1337, 2018.
- [9] N. Karmitsa, A. Airola, T. Pahikkala et T. Pitkämäki, *A Comprehensive Guide to Differential Privacy: From Theory to User Expectations*, arXiv:2509.03294v1, 3 septembre 2025.
- [10] H. Halconrui, *Introduction à la confidentialité différentielle*, diapositives du séminaire de statistique ENSAE – 2A, mars 2026.
- [11] M. Barbaro et T. Zeller Jr., *A Face Is Exposed for AOL Searcher No. 4417749*, The New York Times, 9 août 2006.
- [12] A. Narayanan et V. Shmatikov, *Robust De-anonymization of Large Sparse Datasets*, IEEE Symposium on Security and Privacy, p. 111–125, 2008.
- [13] M. Gymrek, A. L. McGuire, D. Golan, E. Halperin et Y. Erlich, *Identifying Personal Genomes by Surname Inference*, Science, vol. 339, no 6117, p. 321–324, 2013.
- [14] J. Dong, A. Roth et W. J. Su, *Gaussian Differential Privacy*, Journal of the Royal Statistical Society: Series B, vol. 84, no 1, p. 3–37, 2022.
- [15] Laboratoire Analyse, Géométrie et Applications, *Présentation du LAGA*.
[Site officiel, consulté le 22 août 2026.](#)
- [16] Laboratoire Analyse, Géométrie et Applications, *Équipe Probabilités et Statistique*.
[Site officiel, consulté le 22 août 2026.](#)